

第一届天津市五校数学建模联赛赛题

(请先阅读“第一届天津市五校数学建模联赛格式规范”)

B 题 主流大语言模型综合性能评价建模

当前人工智能技术高速发展,国内外大语言模型层出不穷,国产 Kimi K3、DeepSeek、文心一言、通义千问,海外 GPT 系列、Claude 等模型持续迭代更新。不同大模型在超长文本理解、数理逻辑推理、代码生成、多模态处理、知识事实准确性、推理时延、使用成本、算力能耗等方面各具优劣。

普通用户、企事业单位在选择 AI 工具时,大多仅依靠厂商宣传、碎片化网络测评结果,缺少一套客观、量化、多维度的综合评价体系。仅依靠单一测试集准确率无法全面衡量模型综合水平:部分模型擅长长文档解析,但数理推理能力偏弱;部分模型通用对话均衡,但商用调用成本高昂;还有模型在日常闲聊表现亮眼,面对专业学术场景效果较差。如何构建公平、可复现的量化评价框架,横向对比各类大模型综合实力,具有十分重要的现实应用价值。

参赛队伍可通过公开测评榜单、官方公开白皮书、权威第三方评测报告等渠道自主收集主流大模型相关指标数据。请建立数学模型,完成以下问题。



图 1: 大语言模型不断涌现

问题 1 梳理大语言模型性能评价潜在指标,利用已有的公开评测指标和现有大模型在这些指标上的公开性能,开展指标相关性分析,筛选关键评价指标,构建一套完整的大模型综合性能评价指标体系;选择合理数学方法确定指标权重,并论证方法的合

理性。基于构建的评价模型，对选取的多款主流大模型进行综合打分与排名，分析国产 Kimi K3 相较于其他模型存在的竞争优势与现存短板。

问题 2 大模型的价值具备场景依赖性。设定三类典型落地场景：科研长文本分析；大众日常通用对话；计算机代码开发。构建面向差异化场景的评价模型，分别得到三类场景下模型综合排名，分析同一模型在不同场景下评价结果产生差异的内在机理。

问题 3 在工程落地中，模型综合性能与使用成本、算力消耗存在明显权衡关系。建立大模型“综合性能 - 落地成本”效益评估模型，面向不同预算水平的使用者提供模型选型策略；探究成本与模型性能之间潜在的变化规律。

补充说明

1. 参赛队伍不应自行开展对大模型的测评，数据来源应为各模型官方白皮书、AI 评测权威平台公开基准、行业通用标准化测试集结果。参赛队伍应在正文中明确列出数据的清晰来源。
2. 名词解释
 - 模型推理时延：模型接收指令到输出完整回答的响应耗时，是衡量模型工程落地效率的核心指标。
 - 算力能耗：模型单次推理、批量调用所消耗的算力资源与电力能耗，直接决定模型落地运维成本。
 - 性能-成本权衡：大模型综合性能提升与算力消耗、调用成本上升的反向制约关系，是商用落地选型的核心依据
3. 有关 Kimi K3 的参考内容：<https://www.kimi.com/blog/kimi-k3>